AutoEIT Test II: Automated EIT Scoring

This notebook implements and compares two approaches for automatically scoring Spanish EIT responses using the Ortega (2000) meaning-based rubric (0–4 scale).

Approaches:

1. Rule-based — custom algorithm using content word overlap, Levenshtein similarity, and fuzzy matching
2. LLM-based — GPT-4o-mini with the full rubric as a system prompt

Scoring rubric (0–4):

- 4 = Exact repetition
- 3 = Meaning preserved, grammar changes okay
- 2 = More than half of ideas, meaning close but inexact
- 1 = About half of ideas, lots missing
- 0 = Silence, garbled, or minimal repetition

1. Setup & Data Exploration

In [1]:
```
import re
import unicodedata
import json
import os
import numpy as np
import openpyxl
import Levenshtein

print("All imports successful.")
```

```
All imports successful.
```

1.1 Explore the Scoring Dataset

The scoring dataset has 4 participants (different from the transcription test), each with 30 human-transcribed EIT responses. Column D (Score) is empty — that's what we need to fill.

In [2]:
```
wb = openpyxl.load_workbook('data/AutoEIT_Sample_Transcriptions_for_Scoring.
print("Sheets:", wb.sheetnames)

# Show info
ws = wb['Info']
for row in ws.iter_rows(min_row=1, max_row=ws.max_row, values_only=True):
    vals = [v for v in row if v is not None]
```

```
    if vals:
        print(vals[0])
```

```
Sheets: ['Info', '38001-1A', '38002-2A', '38004-2A', '38006-2A']
This file contains 4 sample transcribed EITs to be scored using the EIT scor
ing rubric.
Each sentence should be assigned a score of 0, 1, 2, 3, or 4
All files are EIT vA (same stimuli)
```

In [3]:

```
# Show sample transcriptions from each participant
for sheet_name in ['38001-1A', '38002-2A', '38004-2A', '38006-2A']:
    ws = wb[sheet_name]
    print(f"\n--- {sheet_name} (first 5 items) ---")
    for row in range(2, 7):
        item = ws.cell(row=row, column=1).value
        stimulus = ws.cell(row=row, column=2).value
        transcription = ws.cell(row=row, column=3).value
        print(f"  {item}. Target:  {stimulus}")
        print(f"     Learner: {transcription}")
```

```
--- 38001-1A (first 5 items) ---
  1. Target:  Quiero cortarme el pelo (7)
     Learner: Quiero cortarme el pelo
  2. Target:  El libro está en la mesa (7)
     Learner: El libro está en la mesa
  3. Target:  El carro lo tiene Pedro (8)
     Learner: El carro lo tiene Pedro
  4. Target:  El se ducha cada mañana (9)
     Learner: El se ducha cada mañana
  5. Target:  ¿Qué dice usted que va a hacer hoy? (9)
     Learner: Que dices ustedes se que van a hacer hoy?

--- 38002-2A (first 5 items) ---
  1. Target:  Quiero cortarme el pelo (7)
     Learner: Quiero cortarme el pelo
  2. Target:  El libro está en la mesa (7)
     Learner: El libro está en la mesa.
  3. Target:  El carro lo tiene Pedro (8)
     Learner: El carro tiene pelo.
  4. Target:  El se ducha cada mañana (9)
     Learner: él se ducha cada mañana
  5. Target:  ¿Qué dice usted que va a hacer hoy? (9)
     Learner: en que ustedes x uf x hacer hoy?

--- 38004-2A (first 5 items) ---
  1. Target:  Quiero cortarme el pelo (7)
     Learner: Quiero cortarme el pelo
  2. Target:  El libro está en la mesa (7)
     Learner: El libro está en la mesa
  3. Target:  El carro lo tiene Pedro (8)
     Learner: El carro tiene Pedro
  4. Target:  El se ducha cada mañana (9)
     Learner: El se ducha cada mañana
  5. Target:  ¿Qué dice usted que va a hacer hoy? (9)
     Learner: ¿Qué dices usted vas hacer hoy?

--- 38006-2A (first 5 items) ---
  1. Target:  Quiero cortarme el pelo (7)
     Learner: Quiero cortarme mi pelo
  2. Target:  El libro está en la mesa (7)
     Learner: El libro [pause] está en la mesa
  3. Target:  El carro lo tiene Pedro (8)
     Learner: E-[gibberish] perro
  4. Target:  El se ducha cada mañana (9)
     Learner: El se lucha cada mañana
  5. Target:  ¿Qué dice usted que va a hacer hoy? (9)
     Learner: ¿Qué [gibberish] que vas estoy?
```

1.2 Examine the Rubric

The Ortega (2000) rubric scores based on **meaning preservation**, not grammatical accuracy:

Score	Criteria	Example
4	Exact repetition, form and meaning correct	"Quiero cortarme el pelo" → "Quiero cortarme el pelo"
3	Complete meaning preserved, grammar changes okay. Omitting 'muy' acceptable.	"Dudo que sepa manejar muy bien" → "Dudo que sepa manajar bien"
2	More than half of ideas preserved, meaning close but inexact	"El chico con el que yo salgo es español" → "El chico con yo salgo está bien"
1	About half of ideas, lots missing, or not a self-standing sentence	"Me gustaría que empezara a hacer más calor pronto" → "Me gustaría se .. más calor"
0	Silence, garbled, or only 1-2 words	"Las calles de esta ciudad son muy anchas" → "Las calles..es-[gibberish]..."

Key rules: Self-corrections and false starts are not penalized (score the best final response). Missing accents don't affect scores.

2. Rule-Based Scoring

2.1 Text Preprocessing

Human transcriptions contain annotations that need cleaning: `[pause]`, `[gibberish]`, `xxx`, false starts with `–`, parenthetical notes, etc.

In [4]:
```
FUNCTION_WORDS = {
    "el", "la", "los", "las", "un", "una", "unos", "unas",
    "de", "del", "en", "a", "al", "con", "por", "para", "se",
    "que", "y", "o", "pero", "no", "muy", "mas", "me", "mi",
    "su", "sus", "lo", "le", "les", "es", "son", "fue", "ha",
    "he", "yo", "el", "ella", "nosotros", "usted", "ustedes",
    "tan", "todo", "toda", "todos", "todas", "cada", "este",
    "esta", "esto", "eso", "como", "cuando", "si", "ya",
}

FALSE_FRIENDS = {
    ("ducha", "lucha"), ("lucha", "ducha"),
    ("casa", "cosa"), ("cosa", "casa"),
    ("pero", "perro"), ("perro", "pero"),
    ("carro", "caro"), ("caro", "carro"),
}


def strip_accents(text):
    """Remove accent marks. peliculas == películas"""
    nfkd = unicodedata.normalize('NFKD', text)
    return ''.join(c for c in nfkd if not unicodedata.combining(c))


def clean(text):
```

```
    """Normalize text for comparison."""
    text = text.lower()
    text = re.sub(r'\[.*?\]', '', text)
    text = re.sub(r'\(.*?\)', '', text)
    text = re.sub(r'\bx+\b', '', text)
    text = re.sub(r'\bm+h+\b', '', text)
    text = re.sub(r'\buf\b', '', text)
    text = re.sub(r'\bmeh\b', '', text)
    text = re.sub(r'\b\w+\-\s', '', text)
    text = re.sub(r'\b\w\-', '', text)
    text = re.sub(r'[¿?¡!.,;:\'\"…/]', '', text)
    text = re.sub(r'\s+', ' ', text).strip()
    text = strip_accents(text)
    return text


# Demo: cleaning in action
examples = [
    "Dudo que sepa ma-mastar tan bien (tambien?)",
    "Hay mucha genta que no to- toma nada para el desayuno.",
    "Las calles..es-[gibberish]...",
    "Ella xxx no beber querer",
]
for ex in examples:
    print(f"  Raw:     {ex}")
    print(f"  Cleaned: {clean(ex)}")
    print()
```

```
  Raw:     Dudo que sepa ma-mastar tan bien (tambien?)
  Cleaned: dudo que sepa ma-mastar tan bien

  Raw:     Hay mucha genta que no to- toma nada para el desayuno.
  Cleaned: hay mucha genta que no toma nada para el desayuno

  Raw:     Las calles..es-[gibberish]...
  Cleaned: las calleses-

  Raw:     Ella xxx no beber querer
  Cleaned: ella no beber querer
```

2.2 Scoring Functions

In [5]:
```
def fuzzy_word_match(word1, word2, threshold=0.75):
    """Check if two words are similar enough, excluding false friends."""
    if word1 == word2:
        return True
    if not word1 or not word2:
        return False
    if (word1, word2) in FALSE_FRIENDS:
        return False
    sim = 1 - Levenshtein.distance(word1, word2) / max(len(word1), len(word2
    return sim >= threshold
```

```python
def get_content_words(text):
    words = clean(text).split()
    return [w for w in words if w not in FUNCTION_WORDS and len(w) > 1]


def get_all_words(text):
    return clean(text).split()


def content_overlap(target, response):
    """Content word overlap with fuzzy matching."""
    t_content = get_content_words(target)
    r_content = get_content_words(response)
    if not t_content:
        return 0
    matched = sum(1 for w in t_content
                  if any(fuzzy_word_match(w, rw) for rw in r_content))
    return matched / len(t_content)


def word_overlap(target_words, response_words):
    if not target_words:
        return 0
    matched = sum(1 for w in target_words
                  if any(fuzzy_word_match(w, rw) for rw in response_words))
    return matched / len(target_words)


def levenshtein_sim(target, response):
    a, b = clean(target), clean(response)
    if not a or not b:
        return 0
    return 1 - Levenshtein.distance(a, b) / max(len(a), len(b))


def is_empty_response(response):
    cleaned = clean(response)
    return len(cleaned) == 0 or cleaned in ['', ' ']


def score_eit(target, response):
    """
    Score an EIT response on 0-4 scale.
    4 = exact, 3 = meaning preserved, 2 = half+ ideas,
    1 = ~half ideas, 0 = minimal/nothing
    """
    if not response or is_empty_response(response):
        return 0

    t_words = get_all_words(target)
    r_words = get_all_words(response)
    t_content = get_content_words(target)
    r_content = get_content_words(response)

    lev_sim = levenshtein_sim(target, response)
    content_ov = content_overlap(target, response)
```

```
    word_ov = word_overlap(t_words, r_words)
    r_content_count = sum(1 for w in t_content
                          if any(fuzzy_word_match(w, rw) for rw in r_content
    r_word_count = len(r_words)

    # Score 4: Exact or near-exact
    if content_ov >= 1.0 and lev_sim >= 0.90:
        return 4

    # Score 3: Meaning preserved
    if content_ov >= 0.80 and lev_sim >= 0.60:
        return 3
    if content_ov >= 0.85 and word_ov >= 0.60:
        return 3
    if content_ov >= 0.80 and r_word_count >= len(t_words) * 0.5:
        return 3

    # Score 2: More than half of ideas
    if content_ov >= 0.50 and lev_sim >= 0.40:
        return 2
    if content_ov >= 0.60 and r_word_count >= 3:
        return 2
    if word_ov >= 0.50 and lev_sim >= 0.50 and r_word_count >= 4:
        return 2

    # Score 1: About half, lots missing
    if content_ov >= 0.25 and r_word_count >= 3:
        return 1
    if r_content_count >= 2 and r_word_count >= 3:
        return 1
    if word_ov >= 0.30 and r_word_count >= 3:
        return 1

    return 0


print("Scoring functions defined.")
```

```
Scoring functions defined.
```

2.3 Validate Against Rubric Examples

In [6]:

```
test_cases = [
    ("Quiero cortarme el pelo", "Quiero cortarme el pelo", 4),
    ("El carro lo tiene Pedro", "El carro tiene Pedro", 3),
    ("Dudo que sepa manejar muy bien", "Dudo que sepa manajar bien", 3),
    ("El chico con el que yo salgo es español", "El chico con yo salgo ...um
    ("Después de cenar me fui a dormir tranquilo", "Despues de cenar fue en-
    ("Las calles de esta ciudad son muy anchas", "Las calles..es-[gibberish]
    ("Quiero cortarme el pelo", "Manaña", 0),
    ("El se ducha cada mañana", "El se lucha cada mañana", 2),  # meaning ch
]

print(f"{'Score':>5} | {'Exp':>3} | Target → Response")
print("-" * 80)
```

```
correct = 0
for target, response, expected in test_cases:
    score = score_eit(target, response)
    match = "✓" if score == expected else "✗"
    if score == expected:
        correct += 1
    print(f"  {score}  {match} | {expected:>3} | {target} → {response}")
print(f"\nAccuracy: {correct}/{len(test_cases)}")
```

```
Score | Exp | Target → Response
--------------------------------------------------------------------------
----
  4  ✓ |   4 | Quiero cortarme el pelo → Quiero cortarme el pelo
  3  ✓ |   3 | El carro lo tiene Pedro → El carro tiene Pedro
  3  ✓ |   3 | Dudo que sepa manejar muy bien → Dudo que sepa manajar bien
  2  ✓ |   2 | El chico con el que yo salgo es español → El chico con yo sal
go ...um.. está bien
  2  ✗ |   1 | Después de cenar me fui a dormir tranquilo → Despues de cenar
fue en- tranquilo
  0  ✓ |   0 | Las calles de esta ciudad son muy anchas → Las calles..es-[gi
bberish]...
  0  ✓ |   0 | Quiero cortarme el pelo → Manaña
  2  ✓ |   2 | El se ducha cada mañana → El se lucha cada mañana

Accuracy: 7/8
```

2.4 Score All Participants

In [7]:
```
TARGETS = [
    "Quiero cortarme el pelo",
    "El libro está en la mesa",
    "El carro lo tiene Pedro",
    "El se ducha cada mañana",
    "Qué dice usted que va a hacer hoy",
    "Dudo que sepa manejar muy bien",
    "Las calles de esta ciudad son muy anchas",
    "Puede que llueva mañana todo el día",
    "Las casas son muy bonitas pero caras",
    "Me gustan las películas que acaban bien",
    "El chico con el que yo salgo es español",
    "Después de cenar me fui a dormir tranquilo",
    "Quiero una casa en la que vivan mis animales",
    "A nosotros nos fascinan las fiestas grandiosas",
    "Ella sólo bebe cerveza y no come nada",
    "Me gustaría que el precio de las casas bajara",
    "Cruza a la derecha y después sigue todo recto",
    "Ella ha terminado de pintar su apartamento",
    "Me gustaría que empezara a hacer más calor pronto",
    "El niño al que se le murió el gato está triste",
    "Una amiga mía cuida a los niños de mi vecino",
    "El gato que era negro fue perseguido por el perro",
    "Antes de poder salir él tiene que limpiar su cuarto",
    "La cantidad de personas que fuman ha disminuido",
    "Después de llegar a casa del trabajo tomé la cena",
    "El ladrón al que atrapó la policía era famoso",
```

```
    "Le pedí a un amigo que me ayudara con la tarea",
    "El examen no fue tan difícil como me habían dicho",
    "Serías tan amable de darme el libro que está en la mesa",
    "Hay mucha gente que no toma nada para el desayuno",
]

PARTICIPANTS = ["38001-1A", "38002-2A", "38004-2A", "38006-2A"]

all_rule_scores = {}

for sheet_name in PARTICIPANTS:
    ws = wb[sheet_name]
    scores = []

    print(f"\n{'='*70}")
    print(f"PARTICIPANT {sheet_name}")
    print(f"{'='*70}")
    print(f"{'#':>2} | {'Score':>5} | {'CntOv':>5} | {'LevSim':>6} | Transcr
    print("-" * 80)

    for i in range(30):
        row = i + 2
        transcription = ws.cell(row=row, column=3).value or ""
        target = TARGETS[i]

        score = score_eit(target, transcription)
        c_ov = content_overlap(target, transcription)
        l_sim = levenshtein_sim(target, transcription)

        scores.append({
            "item": i + 1,
            "target": target,
            "transcription": transcription,
            "score": score,
            "content_overlap": round(c_ov, 2),
            "levenshtein_sim": round(l_sim, 2),
        })

        print(f"{i+1:>2} |   {score}   | {c_ov:.2f} | {l_sim:.4f} | {transcr

    all_rule_scores[sheet_name] = scores

    avg = sum(s["score"] for s in scores) / 30
    dist = [sum(1 for s in scores if s["score"] == v) for v in range(5)]
    print(f"\nAverage: {avg:.2f} | Distribution: 0={dist[0]} 1={dist[1]} 2={
```

```
======================================================================
PARTICIPANT 38001-1A
======================================================================
 # | Score | CntOv | LevSim | Transcription
--------------------------------------------------------------------------------
----
 1 |   4   | 1.00 | 1.0000 | Quiero cortarme el pelo
 2 |   4   | 1.00 | 1.0000 | El libro está en la mesa
 3 |   4   | 1.00 | 1.0000 | El carro lo tiene Pedro
 4 |   4   | 1.00 | 1.0000 | El se ducha cada mañana
 5 |   2   | 0.75 | 0.8250 | Que dices ustedes se que van a hacer hoy?
 6 |   3   | 1.00 | 0.8333 | Dudo que sepa manajar bien
 7 |   2   | 0.67 | 0.9500 | Las calles de esta cuidad son muy anchas
 8 |   4   | 1.00 | 0.9714 | Puede que lleva mañana todo el día
 9 |   3   | 1.00 | 0.8750 | Las casas son muy bonitas pero muy cadas
10 |   4   | 1.00 | 1.0000 | Me gustan las peliculas que acaban bien
11 |   2   | 0.67 | 0.6154 | El chico con yo salgo ...um.. está bien
12 |   4   | 1.00 | 1.0000 | Despues de cenar me fui a dormir tranquilo
13 |   3   | 0.80 | 0.8182 | Quiero una casa que vivan los animales
14 |   4   | 1.00 | 0.9348 | A nosotros ..nos fascina los fiestas grandiosos
15 |   4   | 1.00 | 1.0000 | Ella solo bebe cerveza y no come nada
16 |   2   | 0.75 | 0.8750 | Me gustaría que las precios de las casas bajaro
n
17 |   2   | 0.60 | 0.5778 | Cruza a la derecha y sigue a la izquierda
18 |   2   | 0.67 | 0.8571 | Ella ha terminado pintando su apartamento
19 |   1   | 0.40 | 0.4694 | Me gustaría se .. más calor
20 |   3   | 1.00 | 0.7826 | El niño que se murió su gato es triste
21 |   3   | 0.80 | 0.7273 | una amiga de mio cuida su... niños de vecino
22 |   3   | 1.00 | 0.8367 | El gato que era negro era perseguido de(l) perr
o
23 |   3   | 0.83 | 0.8824 | Antes de salir el tiene que limpiar su cuarto
24 |   2   | 0.75 | 0.9149 | La cantidad de personas que fuman ha..desmenido
25 |   2   | 0.67 | 0.7551 | Despues de llegar a casa del trabajo...se...meh
26 |   4   | 1.00 | 0.9333 | El ladrón que atrapó la policia era famoso
27 |   4   | 1.00 | 1.0000 | Le pedí a un amigo que me ayudara con la tarea
28 |   2   | 0.50 | 0.8163 | El examen no fue tan dificil como me decían
29 |   4   | 1.00 | 0.9464 | Serías tan amable pa'- darme el libro que está
en la mesa?
30 |   4   | 1.00 | 0.9796 | Hay mucha genta que no to- toma nada para el de
sayuno.

Average: 3.07 | Distribution: 0=0 1=1 2=9 3=7 4=13

======================================================================
PARTICIPANT 38002-2A
======================================================================
 # | Score | CntOv | LevSim | Transcription
--------------------------------------------------------------------------------
----
 1 |   4   | 1.00 | 1.0000 | Quiero cortarme el pelo
 2 |   4   | 1.00 | 1.0000 | El libro está en la mesa.
 3 |   2   | 0.67 | 0.7826 | El carro tiene pelo.
 4 |   4   | 1.00 | 1.0000 | él se ducha cada mañana
 5 |   2   | 0.50 | 0.5758 | en que ustedes x uf x hacer hoy?
 6 |   1   | 0.25 | 0.5667 | dudo/tu no? sepiar exx muy bien
 7 |   2   | 0.67 | 0.6250 | La calles estén xxxx muy anchas.
```

```
 8 |   2   | 0.75 | 0.7429 | Puede que mañana todo la día
 9 |   3   | 1.00 | 0.8333 | Las casas muy bonitos pero ... casas
10 |   2   | 0.75 | 0.8205 | Me gustan las películas campan bien
11 |   2   | 0.67 | 0.5128 | el chico con ... español
12 |   1   | 0.40 | 0.5476 | después de finar ... él dormir xxx
13 |   2   | 0.60 | 0.5682 | Quiere una casa con animales
14 |   2   | 0.50 | 0.6087 | a nosotros fana-xxx fiestas grandinosas
15 |   1   | 0.20 | 0.3784 | Ella xxx no beber querer
16 |   1   | 0.25 | 0.3556 | Me gusta el casa xxx...
17 |   1   | 0.20 | 0.2444 | en quises a la derecha xxx...
18 |   2   | 0.67 | 0.5476 | Ella tiene termino xx apartamento
19 |   1   | 0.40 | 0.5510 | Me gusta que d-crxxx calor pranto
20 |   3   | 1.00 | 0.6957 | El niño se murió el gato y triste
21 |   0   | 0.20 | 0.3864 | Una amigo que niña ha cuidado
22 |   2   | 0.60 | 0.4490 | El gato negro se fuera el perro son
23 |   1   | 0.33 | 0.4902 | Antes de salir limpio.. el caso
24 |   2   | 0.75 | 0.5106 | la cantidad de las personas fe-xxx fumar
25 |   2   | 0.67 | 0.6327 | Después de llegar la casa pone cena
26 |   1   | 0.40 | 0.4889 | El xxx la policía es famoso
27 |   2   | 0.75 | 0.7391 | Le pedí un amigo con ayuda con mí tarea
28 |   2   | 0.50 | 0.5510 | El examen no es difícil cuando me xxx...
29 |   1   | 0.40 | 0.4182 | El libro están en la mesa.
30 |   2   | 0.67 | 0.5918 | Hay mucho gente no quiere desayuno

Average: 1.90 | Distribution: 0=1 1=9 2=15 3=2 4=3

======================================================================
PARTICIPANT 38004-2A
======================================================================
 # | Score | CntOv | LevSim | Transcription
--------------------------------------------------------------------------------
 1 |   4   | 1.00 | 1.0000 | Quiero cortarme el pelo
 2 |   4   | 1.00 | 1.0000 | El libro está en la mesa
 3 |   3   | 1.00 | 0.8696 | El carro tiene Pedro
 4 |   4   | 1.00 | 1.0000 | El se ducha cada mañana
 5 |   2   | 0.75 | 0.7879 | ¿Qué dices usted vas hacer hoy?
 6 |   4   | 1.00 | 1.0000 | Dudo que sepa manejar muy bien
 7 |   4   | 1.00 | 0.9250 | Las calles de esta ciudad es muy anchas
 8 |   3   | 1.00 | 0.8857 | Pueda que llueva mañana todo día
 9 |   4   | 1.00 | 0.9444 | Las casas son muy bonitas para caras
10 |   2   | 0.75 | 0.7500 | Mis gus..Me gustas las películas que cada bien
11 |   2   | 0.67 | 0.7436 | El chico con esolago(es yo algo?) es español
12 |   4   | 1.00 | 0.9286 | Después de cenar fui a dormir tranquilo
13 |   2   | 0.60 | 0.5147 | Queda una ca..Quiere una casa en queda mis anim
ales...mis an
14 |   1   | 0.25 | 0.5652 | A nosotros fascinmas festivales
15 |   2   | 0.60 | 0.7568 | Ella sólo cerveza y como nada
16 |   3   | 1.00 | 0.8667 | Me gustaría que los precios de la casa bajara
17 |   2   | 0.60 | 0.4915 | Sigue a la derecha y cruzo a la directo..y siqu
e a la direct
18 |   3   | 1.00 | 0.8333 | Ella se terminar pintar su apartamento
19 |   2   | 0.60 | 0.5714 | Me gustaría hacer..xx calores pronto
20 |   3   | 1.00 | 0.7826 | El niño que se murió su gato es triste
21 |   2   | 0.60 | 0.6591 | Una amiga mía cuidado a los vecinos
22 |   1   | 0.40 | 0.3878 | El gato que es negro... [cough]...
```

```
23 |   2   | 0.50 | 0.5490 | Antes de salir tienes xxx cu-cuarto
24 |   2   | 0.50 | 0.6923 | La cantidad de personas que fu-han fumado se di
struy...
25 |   3   | 0.83 | 0.6327 | Después de llegar a-de trabajo cena a mi casa
26 |   3   | 0.80 | 0.8222 | La ladrón que atropó la policía es famoso
27 |   2   | 0.75 | 0.9130 | Le pedí un amigo que me ayuda con la tarea
28 |   2   | 0.50 | 0.4694 | El examen no ..a..va a..fue a tan difícil
29 |   1   | 0.40 | 0.4727 | Sales de donde está mi libro en está mesa
30 |   3   | 0.83 | 0.8163 | Hay mucha gente que no toma tiempo para desayun
o

Average: 2.63 | Distribution: 0=0 1=3 2=12 3=8 4=7

======================================================================
PARTICIPANT 38006-2A
======================================================================
 # | Score | CntOv | LevSim | Transcription
--------------------------------------------------------------------------
----
 1 |   4   | 1.00 | 0.9130 | Quiero cortarme mi pelo
 2 |   4   | 1.00 | 1.0000 | El libro [pause] está en la mesa
 3 |   0   | 0.33 | 0.1739 | E-[gibberish] perro
 4 |   2   | 0.50 | 0.9565 | El se lucha cada mañana
 5 |   0   | 0.00 | 0.4242 | ¿Qué [gibberish] que vas estoy?
 6 |   2   | 0.75 | 0.7500 | Dudo que sepa ma-mastar tan bien (tambien?)
 7 |   0   | 0.00 | 0.3000 | Las calles..es-[gibberish]...
 8 |   2   | 0.75 | 0.5143 | Puede xxx mañana de todo día
 9 |   2   | 0.67 | 0.4444 | A las casa es mu-son bonitas
10 |   2   | 0.75 | 0.7949 | Me gusta las películas que x bien
11 |   3   | 1.00 | 0.8205 | El chico con es el algo (xxx?) es español
12 |   3   | 0.80 | 0.7857 | Después de fenar mi fui a tranquilo
13 |   1   | 0.40 | 0.4773 | Quienen que en el casa ...muchos animales
14 |   2   | 0.50 | 0.7391 | A nosotros fanimos [pause] fiestas grandiosas
15 |   1   | 0.00 | 0.4865 | Ella bebidas cerviamos y no comidas
16 |   1   | 0.25 | 0.3778 | Me gustaría ser..ella...mhh..
17 |   1   | 0.40 | 0.6000 | Cruze a la derecha de siguelo
18 |   3   | 1.00 | 0.7619 | Ella terminado pintar a sus apartmento
19 |   1   | 0.40 | 0.4082 | Me gustaría se..[pause] xxx pronto
20 |   3   | 1.00 | 0.6957 | El niño se murió el gato es muy triste
21 |   2   | 0.60 | 0.5227 | Una mía amiga cuidado a sus niños
22 |   3   | 0.80 | 0.4490 | El gato-el gato quien era el nego de perro
23 |   1   | 0.33 | 0.4118 | Antes de podai e salir..[pause] antes de xxx
24 |   0   | 0.00 | 0.2340 | A la cantan... [pause] muy a xxx
25 |   2   | 0.50 | 0.5714 | Después de llegar [pause] al trabajo...
26 |   1   | 0.40 | 0.5111 | X- ladróna(?)de policio que es famoso
27 |   1   | 0.50 | 0.3913 | Que ped-x una amigo [pause] a su tarea
28 |   2   | 0.50 | 0.4082 | El examen no difícil.. [pause]... [gibberish]
29 |   2   | 0.40 | 0.5091 | El libro que está en la mesa
30 |   1   | 0.33 | 0.2653 | A mucha gente xxx...

Average: 1.73 | Distribution: 0=4 1=9 2=10 3=5 4=2
```

2.5 Write Rule-Based Scores to Excel

In [8]:
```
wb_out = openpyxl.load_workbook('data/AutoEIT_Sample_Transcriptions_for_Scor

for sheet_name, scores in all_rule_scores.items():
    ws = wb_out[sheet_name]
    for s in scores:
        ws.cell(row=s["item"] + 1, column=4, value=s["score"])
    print(f"{sheet_name}: Wrote 30 scores")

os.makedirs("output", exist_ok=True)
wb_out.save("output/AutoEIT_Scores_Complete.xlsx")
print("Saved to output/AutoEIT_Scores_Complete.xlsx")
```

```
38001-1A: Wrote 30 scores
38002-2A: Wrote 30 scores
38004-2A: Wrote 30 scores
38006-2A: Wrote 30 scores
Saved to output/AutoEIT_Scores_Complete.xlsx
```

3. LLM-Based Scoring

For comparison, we score the same items using GPT-4o-mini with the full rubric as a system prompt.

In [9]:
```
from dotenv import load_dotenv
load_dotenv()

from openai import OpenAI

RUBRIC_PROMPT = """You are scoring a Spanish Elicited Imitation Task (EIT).

4 = Exact repetition. Form and meaning both correct without exception.
3 = Complete meaning preserved. Grammar changes that don't affect meaning ar
2 = More than half of idea units preserved. Meaning is close but inexact, ir
1 = Only about half of idea units represented. Lots of important informatior
0 = Silence, garbled/unintelligible, or minimal repetition (only 1-2 words).

IMPORTANT:
- Missing accents (peliculas vs películas) do NOT affect the score.
- False starts marked with '-' should be ignored. Score the best final attem
- [gibberish], [pause], xxx indicate unintelligible or silent portions.
- When in doubt between scores 2 and 3, score 2.

Respond with ONLY valid JSON: {"score": N, "reason": "brief explanation"}
Do not include any other text, markdown, or code blocks."""


client = OpenAI(api_key=os.environ.get("OPENAI_API_KEY"))


def score_with_llm(target, response):
    if not response or response.strip() == "":
        return {"score": 0, "reason": "No response / silence"}
    try:
        completion = client.chat.completions.create(
```

```
            model="gpt-4o-mini",
            messages=[
                {"role": "system", "content": RUBRIC_PROMPT},
                {"role": "user", "content": f"Target sentence: {target}\nLea
            ],
            temperature=0.0,
            max_tokens=100,
        )
        result_text = completion.choices[0].message.content.strip()
        if result_text.startswith("```"):
            result_text = result_text.split("\n", 1)[1]
            result_text = result_text.rsplit("```", 1)[0]
        result = json.loads(result_text)
        return {"score": int(result["score"]), "reason": result.get("reason"
    except Exception as e:
        print(f"    LLM error: {e}")
        return {"score": -1, "reason": f"Error: {e}"}


print("LLM scoring function ready.")
```

```
LLM scoring function ready.
```

In [10]:

```
# Score all participants with LLM and compare
all_comparisons = {}

for sheet_name in PARTICIPANTS:
    rule_scores = all_rule_scores[sheet_name]
    comparisons = []

    print(f"\n{'='*80}")
    print(f"PARTICIPANT {sheet_name}")
    print(f"{'='*80}")
    print(f"{'#':>2} | {'Rule':>4} | {'LLM':>3} | {'Match':>5} | Transcripti
    print("-" * 80)

    for s in rule_scores:
        llm_result = score_with_llm(s["target"], s["transcription"])
        llm_score = llm_result["score"]
        rule_score = s["score"]

        match = "✓" if rule_score == llm_score else f"Δ{abs(rule_score - llm

        comparisons.append({
            "item": s["item"],
            "transcription": s["transcription"],
            "rule_score": rule_score,
            "llm_score": llm_score,
            "llm_reason": llm_result["reason"],
        })

        print(f"{s['item']:>2} |   {rule_score}  |  {llm_score}  | {match:>5

    all_comparisons[sheet_name] = comparisons

    rule_avg = sum(c["rule_score"] for c in comparisons) / 30
```

```
    llm_avg = sum(c["llm_score"] for c in comparisons if c["llm_score"] >= 0
    agree = sum(1 for c in comparisons if c["rule_score"] == c["llm_score"])
    close = sum(1 for c in comparisons if abs(c["rule_score"] - c["llm_score

    print(f"\nRule avg: {rule_avg:.2f} | LLM avg: {llm_avg:.2f}")
    print(f"Exact agreement: {agree}/30 ({agree/30*100:.0f}%)")
    print(f"Within 1 point:  {close}/30 ({close/30*100:.0f}%)")
```

```
================================================================================
PARTICIPANT 38001-1A
================================================================================
 # | Rule | LLM | Match | Transcription
--------------------------------------------------------------------------------
 1 |   4  |  4  |     ✓ | Quiero cortarme el pelo
 2 |   4  |  4  |     ✓ | El libro está en la mesa
 3 |   4  |  4  |     ✓ | El carro lo tiene Pedro
 4 |   4  |  4  |     ✓ | El se ducha cada mañana
 5 |   2  |  2  |     ✓ | Que dices ustedes se que van a hacer hoy?
 6 |   3  |  3  |     ✓ | Dudo que sepa manajar bien
 7 |   2  |  4  |    Δ2 | Las calles de esta cuidad son muy anchas
 8 |   4  |  2  |    Δ2 | Puede que lleva mañana todo el día
 9 |   3  |  3  |     ✓ | Las casas son muy bonitas pero muy cadas
10 |   4  |  4  |     ✓ | Me gustan las peliculas que acaban bien
11 |   2  |  2  |     ✓ | El chico con yo salgo ...um.. está bien
12 |   4  |  4  |     ✓ | Despues de cenar me fui a dormir tranquilo
13 |   3  |  2  |    Δ1 | Quiero una casa que vivan los animales
14 |   4  |  2  |    Δ2 | A nosotros ..nos fascina los fiestas grandiosos
15 |   4  |  4  |     ✓ | Ella solo bebe cerveza y no come nada
16 |   2  |  2  |     ✓ | Me gustaría que las precios de las casas bajaron
17 |   2  |  2  |     ✓ | Cruza a la derecha y sigue a la izquierda
18 |   2  |  3  |    Δ1 | Ella ha terminado pintando su apartamento
19 |   1  |  1  |     ✓ | Me gustaría se .. más calor
20 |   3  |  2  |    Δ1 | El niño que se murió su gato es triste
21 |   3  |  2  |    Δ1 | una amiga de mio cuida su... niños de vecino
22 |   3  |  3  |     ✓ | El gato que era negro era perseguido de(l) perro
23 |   3  |  3  |     ✓ | Antes de salir el tiene que limpiar su cuarto
24 |   2  |  3  |    Δ1 | La cantidad de personas que fuman ha..desmenido
25 |   2  |  0  |    Δ2 | Despues de llegar a casa del trabajo...se...meh
26 |   4  |  3  |    Δ1 | El ladrón que atrapó la policia era famoso
27 |   4  |  4  |     ✓ | Le pedí a un amigo que me ayudara con la tarea
28 |   2  |  3  |    Δ1 | El examen no fue tan dificil como me decían
29 |   4  |  3  |    Δ1 | Serías tan amable pa'- darme el libro que está en
la me
30 |   4  |  4  |     ✓ | Hay mucha genta que no to- toma nada para el desay
uno.

Rule avg: 3.07 | LLM avg: 2.87
Exact agreement: 18/30 (60%)
Within 1 point:  26/30 (87%)

================================================================================
PARTICIPANT 38002-2A
================================================================================
 # | Rule | LLM | Match | Transcription
--------------------------------------------------------------------------------
 1 |   4  |  4  |     ✓ | Quiero cortarme el pelo
 2 |   4  |  4  |     ✓ | El libro está en la mesa.
 3 |   2  |  1  |    Δ1 | El carro tiene pelo.
```

```
 4 |   4  |  4  |     ✓ | él se ducha cada mañana
 5 |   2  |  0  |    Δ2 | en que ustedes x uf x hacer hoy?
 6 |   1  |  1  |     ✓ | dudo/tu no? sepiar exx muy bien
 7 |   2  |  1  |    Δ1 | La calles estén xxxx muy anchas.
 8 |   2  |  2  |     ✓ | Puede que mañana todo la día
 9 |   3  |  1  |    Δ2 | Las casas muy bonitos pero ... casas
10 |   2  |  2  |     ✓ | Me gustan las películas campan bien
11 |   2  |  1  |    Δ1 | el chico con ... español
12 |   1  |  1  |     ✓ | después de finar ... él dormir xxx
13 |   2  |  1  |    Δ1 | Quiere una casa con animales
14 |   2  |  2  |     ✓ | a nosotros fana-xxx fiestas grandinosas
15 |   1  |  0  |    Δ1 | Ella xxx no beber querer
16 |   1  |  0  |    Δ1 | Me gusta el casa xxx...
17 |   1  |  0  |    Δ1 | en quises a la derecha xxx...
18 |   2  |  1  |    Δ1 | Ella tiene termino xx apartamento
19 |   1  |  1  |     ✓ | Me gusta que d-crxxx calor pranto
20 |   3  |  1  |    Δ2 | El niño se murió el gato y triste
21 |   0  |  1  |    Δ1 | Una amigo que niña ha cuidado
22 |   2  |  1  |    Δ1 | El gato negro se fuera el perro son
23 |   1  |  1  |     ✓ | Antes de salir limpio.. el caso
24 |   2  |  0  |    Δ2 | la cantidad de las personas fe-xxx fumar
25 |   2  |  1  |    Δ1 | Después de llegar la casa pone cena
26 |   1  |  1  |     ✓ | El xxx la policía es famoso
27 |   2  |  1  |    Δ1 | Le pedí un amigo con ayuda con mí tarea
28 |   2  |  1  |    Δ1 | El examen no es difícil cuando me xxx...
29 |   1  |  1  |     ✓ | El libro están en la mesa.
30 |   2  |  1  |    Δ1 | Hay mucho gente no quiere desayuno

Rule avg: 1.90 | LLM avg: 1.23
Exact agreement: 12/30 (40%)
Within 1 point:  26/30 (87%)

================================================================================
PARTICIPANT 38004-2A
================================================================================
 # | Rule | LLM | Match | Transcription
--------------------------------------------------------------------------------
 1 |   4  |  4  |     ✓ | Quiero cortarme el pelo
 2 |   4  |  4  |     ✓ | El libro está en la mesa
 3 |   3  |  3  |     ✓ | El carro tiene Pedro
 4 |   4  |  4  |     ✓ | El se ducha cada mañana
 5 |   2  |  3  |    Δ1 | ¿Qué dices usted vas hacer hoy?
 6 |   4  |  4  |     ✓ | Dudo que sepa manejar muy bien
 7 |   4  |  3  |    Δ1 | Las calles de esta ciudad es muy anchas
 8 |   3  |  3  |     ✓ | Pueda que llueva mañana todo día
 9 |   4  |  2  |    Δ2 | Las casas son muy bonitas para caras
10 |   2  |  2  |     ✓ | Mis gus..Me gustas las películas que cada bien
11 |   2  |  1  |    Δ1 | El chico con esolago(es yo algo?) es español
12 |   4  |  3  |    Δ1 | Después de cenar fui a dormir tranquilo
13 |   2  |  1  |    Δ1 | Queda una ca..Quiere una casa en queda mis animale
s...m
14 |   1  |  1  |     ✓ | A nosotros fascinmas festivales
15 |   2  |  2  |     ✓ | Ella sólo cerveza y como nada
```

```
16 |   3  |  3  |     ✓ | Me gustaría que los precios de la casa bajara
17 |   2  |  2  |     ✓ | Sigue a la derecha y cruzo a la directo..y sique a
la d
18 |   3  |  1  |    Δ2 | Ella se terminar pintar su apartamento
19 |   2  |  1  |    Δ1 | Me gustaría hacer..xx calores pronto
20 |   3  |  2  |    Δ1 | El niño que se murió su gato es triste
21 |   2  |  1  |    Δ1 | Una amiga mía cuidado a los vecinos
22 |   1  |  1  |     ✓ | El gato que es negro... [cough]...
23 |   2  |  1  |    Δ1 | Antes de salir tienes xxx cu-cuarto
24 |   2  |  1  |    Δ1 | La cantidad de personas que fu-han fumado se distr
uy...
25 |   3  |  2  |    Δ1 | Después de llegar a-de trabajo cena a mi casa
26 |   3  |  2  |    Δ1 | La ladrón que atropó la policía es famoso
27 |   2  |  2  |     ✓ | Le pedí un amigo que me ayuda con la tarea
28 |   2  |  1  |    Δ1 | El examen no ..a..va a..fue a tan difícil
29 |   1  |  1  |     ✓ | Sales de donde está mi libro en está mesa
30 |   3  |  2  |    Δ1 | Hay mucha gente que no toma tiempo para desayuno

Rule avg: 2.63 | LLM avg: 2.10
Exact agreement: 14/30 (47%)
Within 1 point:  28/30 (93%)

==============================================================================
====
PARTICIPANT 38006-2A
==============================================================================
====
 # | Rule | LLM | Match | Transcription
------------------------------------------------------------------------------
----
 1 |   4  |  3  |    Δ1 | Quiero cortarme mi pelo
 2 |   4  |  4  |     ✓ | El libro [pause] está en la mesa
 3 |   0  |  0  |     ✓ | E-[gibberish] perro
 4 |   2  |  2  |     ✓ | El se lucha cada mañana
 5 |   0  |  0  |     ✓ | ¿Qué [gibberish] que vas estoy?
 6 |   2  |  2  |     ✓ | Dudo que sepa ma-mastar tan bien (tambien?)
 7 |   0  |  0  |     ✓ | Las calles..es-[gibberish]...
 8 |   2  |  1  |    Δ1 | Puede xxx mañana de todo día
 9 |   2  |  1  |    Δ1 | A las casa es mu-son bonitas
10 |   2  |  2  |     ✓ | Me gusta las películas que x bien
11 |   3  |  1  |    Δ2 | El chico con es el algo (xxx?) es español
12 |   3  |  1  |    Δ2 | Después de fenar mi fui a tranquilo
13 |   1  |  1  |     ✓ | Quienen que en el casa ...muchos animales
14 |   2  |  2  |     ✓ | A nosotros fanimos [pause] fiestas grandiosas
15 |   1  |  1  |     ✓ | Ella bebidas cerviamos y no comidas
16 |   1  |  0  |    Δ1 | Me gustaría ser..ella...mhh..
17 |   1  |  1  |     ✓ | Cruze a la derecha de siguelo
18 |   3  |  1  |    Δ2 | Ella terminado pintar a sus apartmento
19 |   1  |  1  |     ✓ | Me gustaría se..[pause] xxx pronto
20 |   3  |  1  |    Δ2 | El niño se murió el gato es muy triste
21 |   2  |  2  |     ✓ | Una mía amiga cuidado a sus niños
22 |   3  |  1  |    Δ2 | El gato-el gato quien era el nego de perro
23 |   1  |  0  |    Δ1 | Antes de podai e salir..[pause] antes de xxx
24 |   0  |  0  |     ✓ | A la cantan... [pause] muy a xxx
25 |   2  |  1  |    Δ1 | Después de llegar [pause] al trabajo...
26 |   1  |  1  |     ✓ | X- ladróna(?)de policio que es famoso
```

```
27 |   1  |  1  |     ✓ | Que ped-x una amigo [pause] a su tarea
28 |   2  |  0  |    Δ2 | El examen no difícil.. [pause]... [gibberish]
29 |   2  |  2  |     ✓ | El libro que está en la mesa
30 |   1  |  0  |    Δ1 | A mucha gente xxx...

Rule avg: 1.73 | LLM avg: 1.10
Exact agreement: 17/30 (57%)
Within 1 point:  24/30 (80%)
```

4. Comparison Summary

In [11]:
```
print(f"{'Participant':>12} | {'Rule Avg':>8} | {'LLM Avg':>8} | {'Exact':>6
print("-" * 60)

for sheet_name in PARTICIPANTS:
    comparisons = all_comparisons[sheet_name]
    rule_avg = sum(c["rule_score"] for c in comparisons) / 30
    llm_avg = sum(c["llm_score"] for c in comparisons if c["llm_score"] >= 0
    agree = sum(1 for c in comparisons if c["rule_score"] == c["llm_score"])
    close = sum(1 for c in comparisons if abs(c["rule_score"] - c["llm_score
    print(f"{sheet_name:>12} | {rule_avg:>8.2f} | {llm_avg:>8.2f} | {agree:>
```

```
 Participant | Rule Avg |  LLM Avg |  Exact |  Within 1
------------------------------------------------------------
    38001-1A |     3.07 |     2.87 |   18/30 |      26/30
    38002-2A |     1.90 |     1.23 |   12/30 |      26/30
    38004-2A |     2.63 |     2.10 |   14/30 |      28/30
    38006-2A |     1.73 |     1.10 |   17/30 |      24/30
```

In [12]:
```
# Error analysis: where do the methods disagree most?
print("Largest disagreements (Δ2+):")
print("=" * 90)

for sheet_name in PARTICIPANTS:
    for c in all_comparisons[sheet_name]:
        diff = abs(c["rule_score"] - c["llm_score"])
        if diff >= 2:
            print(f"\n  [{sheet_name}] Item {c['item']}")
            print(f"  Rule: {c['rule_score']} | LLM: {c['llm_score']}")
            print(f"  Transcription: {c['transcription'][:70]}")
            print(f"  LLM reason:    {c['llm_reason'][:80]}")
```

```
Largest disagreements (Δ2+):
==============================================================================
==============

  [38001-1A] Item 7
  Rule: 2 | LLM: 4
  Transcription: Las calles de esta cuidad son muy anchas
  LLM reason:    Exact repetition. Form and meaning both correct without exc
eption, with only a m

  [38001-1A] Item 8
  Rule: 4 | LLM: 2
  Transcription: Puede que lleva mañana todo el día
  LLM reason:    The response preserves the main idea of the sentence but us
es 'lleva' instead of

  [38001-1A] Item 14
  Rule: 4 | LLM: 2
  Transcription: A nosotros ..nos fascina los fiestas grandiosos
  LLM reason:    The response preserves the main idea but has grammatical er
rors ('fascina' inste

  [38001-1A] Item 25
  Rule: 2 | LLM: 0
  Transcription: Despues de llegar a casa del trabajo...se...meh
  LLM reason:    Response is unintelligible and does not constitute a self-s
tanding sentence.

  [38002-2A] Item 5
  Rule: 2 | LLM: 0
  Transcription: en que ustedes x uf x hacer hoy?
  LLM reason:    The response is garbled and unintelligible, with no meaning
ful repetition of the

  [38002-2A] Item 9
  Rule: 3 | LLM: 1
  Transcription: Las casas muy bonitos pero ... casas
  LLM reason:    Only part of the idea is represented; important information
is missing, and the

  [38002-2A] Item 20
  Rule: 3 | LLM: 1
  Transcription: El niño se murió el gato y triste
  LLM reason:    Only about half of the idea units are represented. The resp
onse misses the key e

  [38002-2A] Item 24
  Rule: 2 | LLM: 0
  Transcription: la cantidad de las personas fe-xxx fumar
  LLM reason:    Response is unintelligible and does not convey the meaning
of the target sentenc

  [38004-2A] Item 9
  Rule: 4 | LLM: 2
  Transcription: Las casas son muy bonitas para caras
  LLM reason:    The response preserves the main idea but changes 'pero' to
```

```
'para', which alters

  [38004-2A] Item 18
  Rule: 3 | LLM: 1
  Transcription: Ella se terminar pintar su apartamento
  LLM reason:    Only about half of the idea units are represented. The verb
is incorrect and the

  [38006-2A] Item 11
  Rule: 3 | LLM: 1
  Transcription: El chico con es el algo (xxx?) es español
  LLM reason:    Only about half of the idea units are represented. Importan
t information is miss

  [38006-2A] Item 12
  Rule: 3 | LLM: 1
  Transcription: Después de fenar mi fui a tranquilo
  LLM reason:    Only about half of the idea units are represented. Importan
t information is miss

  [38006-2A] Item 18
  Rule: 3 | LLM: 1
  Transcription: Ella terminado pintar a sus apartmento
  LLM reason:    Only about half of the idea units are represented. Importan
t information is miss

  [38006-2A] Item 20
  Rule: 3 | LLM: 1
  Transcription: El niño se murió el gato es muy triste
  LLM reason:    Only about half of the idea units are represented. The mean
ing is significantly

  [38006-2A] Item 22
  Rule: 3 | LLM: 1
  Transcription: El gato-el gato quien era el nego de perro
  LLM reason:    Only about half of the idea units are represented. Importan
t information is miss

  [38006-2A] Item 28
  Rule: 2 | LLM: 0
  Transcription: El examen no difícil.. [pause]... [gibberish]
  LLM reason:    Response is unintelligible and does not constitute a self-s
tanding sentence.
```

5. Key Findings

Both methods rank participants correctly

The proficiency ordering (38001 > 38004 > 38002 > 38006) is consistent across both approaches.

LLM scores consistently lower

The LLM has a stricter interpretation of meaning preservation, particularly for borderline cases. This may be because the rubric instruction "when in doubt, score 2" is applied more aggressively.

Within-1-point agreement is 80–90%

This is comparable to inter-rater reliability between human scorers on EIT tasks.

Biggest disagreements are on rubric boundaries

The 2/3 boundary ("meaning close but inexact" vs. "meaning preserved") accounts for most disagreements — the same boundary that causes disagreement among human raters.

Complementary strengths

- **Rule-based:** Fast, free, deterministic. Works well for clear cases (4s and 0s).
- **LLM-based:** Better semantic understanding. Handles meaning changes that word overlap misses (e.g., "para" vs. "pero"). Provides reasoning.

Future directions

- Calibrate against human rater scores to determine which approach is more accurate
- Ensemble the two methods (e.g., use rule-based for clear cases, LLM for borderline)
- Fine-tune a smaller model on scored EIT data to reduce costs